

Fouilles de données



**PARIS
DIDEROT**

ENSEIGNANT : Anne-Claire HAURY

UNIVERSITÉ PARIS DIDEROT

MASTER INFORMATIQUE 2^{ÈME} ANNÉE

Quentin BOUILLAGET - Stéphane SCHMIDELY

Sommaire

I) Introduction	4
II) Méthodes	7
A. Base de données	11
B. Langage et librairies	11
C. Traitements	12
D. Récupération des données	13
III) Résultats	13
IV) Discussion	17
A. Analyse de notre travail	19
B. Améliorations/extensions possibles	19
V) Conclusion	20
VI) Equipe	23
A. Répartition des tâches	27

Préface

Dans le cadre de l'UE « Fouilles de données », nous devons concevoir une application mettant en pratique les différentes notions et algorithmes utilisés en datamining.

Pour notre projet, nous sommes parti sur un logiciel capable de recommander des produits en fonction des tweets d'un utilisateur. Ce document a pour but d'expliquer le problème soulevé, nos motivations ainsi que les différents moyens mis en place pour le résoudre.

Introduction

L'application que nous avons mis en place souhaite répondre à la problématique suivante : « Pouvoir proposer à un utilisateur des produits qui lui correspondent ». Nous voulions pouvoir permettre à un utilisateur de lui recommander différents produits basés sur le contenu qu'il publie, qu'il aime ...

Méthodes

Base de données

Malgré le fait que l'application fonctionne en temps-réel, nous avons eu besoin de créer une base de données. Nous nous en servons lorsque nous devons comparé la liste des tweets d'un utilisateur à celle des autres utilisateurs. Pour cela, des informations ont été collectées et sauvegardées.

Nous stockons dans notre base de données, une

Ces données seront utilisées lors des traitements que nous sommes amenés à faire dans notre application qui résulte du choix de l'utilisateur à un instant donné. En effet, le contenu dépendra de l'utilisateur sélectionné mais aussi du contenu publié par ce dernier au moment de la requête et des tweets des autres utilisateurs présents dans la base de données.

Langage et librairies

Nous avons choisi de développer l'application en Python notamment dû au fait qu'il dispose d'un certains nombre de librairies dédié au datamining. Par ailleurs, ce projet était aussi une occasion pour nous d'apprendre ou de pratiquer de nouveau ce langage. Enfin, il nous a permis de découvrir un nouveau framework Web : Django. Au niveau de la base de données, nous avons pris SQLite dû fait de sa simplicité d'administration mais aussi au vue des données que nous avons prévu de sauvegarder.

Lors du développement de notre application, nous avons eu recours à plusieurs librairies externes :

Amazon Product : <https://pypi.python.org/pypi/python-amazon-product-api/>

Hunspell : <https://pypi.python.org/pypi/hunspell>

Tweepy : <https://github.com/tweepy/tweepy>

Amazon Product

Hunspell

Nous avons décidé d'avoir recours à cette librairie car elle permet entre autres de vérifier si des mots existent dans les dictionnaires français et anglais, de proposer des synonymes et de donner la racine d'un mot dans le but d'uniformiser et de corriger les données que nous allions recevoir en entrée.

Par ailleurs, Hunspell est une librairie utilisée dans de nombreux programmes comme LibreOffice, Firefox, Thunderbird, Google Chrome ce qui nous a conforté dans notre choix.

Tweepy

Tweepy est une des nombreuses librairies disponible en Python pour interfacer avec l'API de Twitter. Nous avons décidé de la choisir en raison de sa popularité mais aussi grâce à sa facilité d'utilisation. Elle nous permet de récupérer les différents tweets d'un utilisateur donné mais aussi lors de la saisie du nom du compte Twitter afin de lui suggérer différents profils associés à sa saisie.

Traitements

La seule action requise par l'utilisateur est de saisir le nom du compte Twitter dont il souhaite connaître les différents produits associés à ses contenus. Une fois la validation effectuée, le programme se charge de :

- récupérer les 100 derniers tweets du profil choisi
- nettoyer chacun des tweets
 - supprimer les URL
 - supprimer les smileys
 - supprimer la ponctuation
 - supprimer le # des hashtags
 - supprimer les références au profil (@compte)
 - supprimer les prépositions/stop-words (le, la, du ...)
 - convertir le tout en minuscule
- corriger les mots et remplacer par la racine de chaque mot
 - tester si le mot appartient au dictionnaire français ou anglais
 - s'il appartient à un des deux dictionnaires, alors on cherche la racine du mot dans la langue correspondante
 - s'il existe dans les deux dictionnaires, on se base sur la langue du tweet et on cherche sa racine
 - s'il n'existe dans aucun des deux, on regarde s'il existe un mot se rapprochant le plus du mot en recherchant dans le dictionnaire correspondant à la langue du tweet sinon on l'ajoute dans les mots inconnus (ex de cas particulier : marque, nom propre ...)
- séparer le corps du tweet, les hashtags
- création d'une liste de 'tokens'
- calcul du TD-IDF sur l'ensemble des tokens afin de déterminer les mots-clés majoritaires avec un point plus fort sur les mots venant des hashtags par rapport aux documents stockés en base
- requête vers l'API d'Amazon pour récupérer une liste de produits en lien avec les mots-clés calculés précédemment

La majeure partie de l'application se situe au niveau du traitement des tweets et au niveau du calcul du TD-IDF afin de pouvoir calculer les mots-clés au plus proche du contenu publié par le compte Twitter sélectionné.

Récupération des données

Résultats

Discussion

Analyse de notre travail

Cette application nous a amenés à travailler aussi bien sur le back-end que sur le front-end. Nous avons donc eu la possibilité de travailler les algorithmes de traitement mais aussi sur le rendu de notre site web.

Nous n'avons pas rencontré de problèmes au niveau du front-end : l'affichage et la modification du rendu des éléments n'ont pas été très compliqués.

Concernant le cœur de notre application, nous avons rencontrés différents soucis techniques lors du traitement des tweets et lors du calcul du TD-IDF.

Traitements des documents

Sur les tweets que nous recevons, nous effectuons une série d'actions afin de pouvoir au maximum nettoyer la chaîne de caractères avant le calcul du TD-IDF. Le traitement le plus important consiste à corriger les éventuelles fautes de phrases et d'orthographe des différents mots.

Pour pallier à ce problème, nous avons eu recours à un dictionnaire français/anglais qui nous a permis de tester l'existence d'un mot mais aussi de pouvoir nous donner des synonymes et la racine d'un mot.

TD-IDF

Concernant le TD-IDF, nous étions parti sur le fait de calculer le TD-IDF d'un document qui serait constitué par l'ensemble des tweets d'un utilisateur. Or il s'est avéré que le résultat n'était pas assez correct et que nous ne satisfaisions pas toutes les contraintes imposées par cette méthode. En effet, afin d'avoir un résultat optimal et complet, il est nécessaire d'avoir d'autres documents afin de pouvoir comparer la liste des tweets de l'utilisateur à d'autres tweets venant de profils variés.

Nous avons donc mis en place une base de données afin de stocker différentes informations concernant les précédents documents déjà étudiés et qui serviraient maintenant de documents de « référence ».

Améliorations/extensions possibles

Améliorations

L'algorithme de notre application pourrait être sujet à amélioration. Constituant le cœur de notre application, cette dernière est essentielle afin d'obtenir des produits en adéquation avec les tweets publiés par l'utilisateur.

D'autres traitements que ceux existant pourraient donc éventuellement être effectués sur les différents tweets afin d'affiner encore plus la requête. Par exemple, il pourrait être possible de mettre des poids en fonction du tweet : normal, retweeté, favorisé/aimé

ou encore favorisé et retweeter. En fonction de ces informations, nous pourrions éventuellement rajouter des poids sur les mots du tweet en question afin de lui donner plus d'importance lors du TD-IDF notamment.

Une autre suggestion d'amélioration pourrait être l'analyse des images associées aux tweets. Il pourrait être ainsi possible de l'analyser afin de ressortir de nouveaux mots clés en relation avec le média.

Extensions

Une des première extensions pourrait être de se baser non plus sur les utilisateurs mais sur les hashtags. Ainsi, nous pourrions, par exemple, proposer une liste de produits en relation avec un « trending topics ».

A cette époque où tout le monde cherche des cadeaux de Noël, il pourrait être possible d'ajouter un montant minimum/maximum pour les produits proposés. Ainsi, notre application recommanderait une liste de produits compris dans son budget et en adéquation avec les goûts de la personne.

La dernière extension concernerait l'ajout de Facebook. En effet, nous pourrions récupérer les contenus publiés par un utilisateur de Facebook et effectuer le même traitement que ce que nous faisons pour Twitter. Toutes les fonctionnalités précédemment évoquées seraient aussi valable pour ce réseau social.

Conclusion

Ce projet nous a permis de mettre en pratique les différentes notions et méthodes de datamining vu en cours appliqué à un cas concret. Nous avons du faire face à différents problèmes soulevés par les grandes quantités de données reçues notamment au niveau du contenu des tweets de chaque utilisateur.

Il nous a aussi permis de découvrir plus en profondeur Python et d'utiliser différentes librairies en lien avec les API de Twitter et d'Amazon.

Ce logiciel possède un grand nombres d'extensions possibles en commençant par la possibilité de récupérer du contenu d'un utilisateur depuis son compte Facebook. Il existe encore bien d'autres ajouts imaginables qui permettraient de rendre l'application encore plus précise et plus proche des recommandations que le site web pourrait leur faire.

Equipe

Répartition des tâches

Dans le cadre de notre projet, nous devions avoir recours à deux API : celle de Twitter afin de récupérer les différents tweets d'un utilisateur et Amazon pour qu'il nous renvoie une liste de produits associées aux différents mots clés que nous lui fournissons en paramètre.

Stéphane s'est chargé de mettre en place l'interface avec l'API Twitter mais aussi de nettoyer et « harmoniser » les différents tweets de l'utilisateur afin de pouvoir ensuite récupérer des mots-clés à soumettre à Amazon. De son côté, Quentin s'est occupé de l'API Amazon et du TD-IDF avec tout ce que cela implique (création de la base de donnée, calcul du TD-IDF ...).

Le site web a été développé par nous deux.

Listes des figures